ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP

ỨNG DỤNG GIẢI THUẬT DI TRUYỀN CHO BÀI TOÁN XÁC ĐỊNH VÙNG QUAN TRỌNG ĐỐI VỚI DỰ ĐOÁN CỦA MÔ HÌNH PHÂN LỚP BỆNH LÁ

Sinh viên thực hiện:
21120604 - Nguyễn Quang Vinh

Giảng viên hướng dẫn:
ThS. Lê Nhựt Nam
ThS. Nguyễn Ngọc Đức

Tháng 7/2026

1. Động lực nghiên cứu

- Phát hiện sớm bệnh trên lá cây có thể giúp giảm thiểu thiệt hại về mặt kinh tế.
- Sự phát triển của các kỹ thuật giải thích nên hướng đến khả năng áp dụng rộng rãi trong nhiều trường hợp, ngữ cảnh khác nhau.
- Đề tài này tập trung vào thuật toán giải thích độc lập với mô hình và thực hiện trên mô hình phân lớp bệnh lá.

2. Phát biểu bài toán

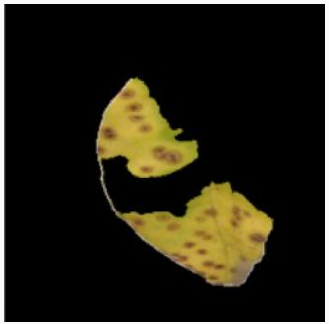
Đầu vào: Ảnh lá và mô hình phân lớp bệnh lá.

Đầu ra: Ảnh giải thích cho dự đoán của mô hình.



⟹ Mô hình phân lớp (ResNet-50) ⟹ Canker

Hình: Ảnh được mô hình dự đoán thuộc lớp Canker (bệnh loét).



Hình: Ví dụ minh họa cho một ảnh giải thích.

3. Các công trình nghiên cứu liên quan

Độc lập với mô hình: LIME

- Cơ chế: tạo mẫu nhiễu xung quanh dữ liệu x → gán trọng số theo khoảng cách → huấn luyện mô hình đơn giản để xấp xỉ cục bộ.
- Hàm mục tiêu: LIME tìm mô hình giải thích bằng cách cực tiểu hóa:

$$\xi(x) = \arg\min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

3. Các công trình nghiên cứu liên quan

Phụ thuộc vào mô hình: Grad-CAM

- Cơ chế: tính gradient của điểm dự đoán → trích xuất trọng số của từng bản đồ đặc trưng → tổ hợp tuyến tính và loại bỏ các giá trị âm.
- Công thức:
  - Tính trọng số của bản đồ đặc trưng:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{i,j}^k}$$

  - Tạo bản đồ nhiệt:

$$L_{Grad-CAM}^c = ReLU\left(\sum_k \alpha_k^c A^k\right)$$

4. Phương pháp MOGAE

Model-agnostic local explanation: Multi-objective genetic algorithm explainer

Hossein Nematzadeh [a,*], José García-Nieto [a,b], Sandro Hurtado [a], José F. Aldana-Montes [a,b], Ismael Navas-Delgado [a,b]

[a] ITIS Software, Universidad de Málaga, Arquitecto Francisco Peñalosa 18, Málaga, 29071, Spain
[b] Departamento de Lenguajes y Ciencias de la Computación, Universidad de Málaga, Málaga, Spain

ARTICLE INFO

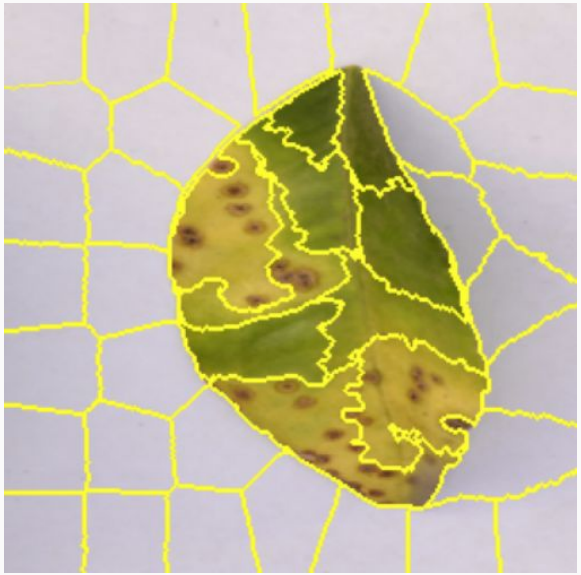
Keywords:
Citrus diseases
Multi-objective genetic algorithm explainer
Non-dominated Sorting Genetic Algorithm II
Residual network 50 layers
Local Interpretable Model-agnostic Explanations
Melanoma detection

ABSTRACT

Late detection of plant diseases leads to irreparable losses for farmers, threatening global food security, economic stability, and environmental sustainability. This research introduces the Multi-Objective Genetic Algorithm Explainer (MOGAE), a novel model-agnostic local explainer for image data aimed at the early detection of citrus diseases. MOGAE enhances eXplainable Artificial Intelligence (XAI) by leveraging the Non-dominated Sorting Genetic Algorithm II (NSGA-II) with an adaptive Bit Flip Mutation (BFM) incorporating densify and sparsify operators to adjust superpixel granularity automatically. This innovative approach simplifies the explanation process by eliminating several critical hyperparameters required by traditional methods like Local Interpretable Model-Agnostic Explanations (LIME). To develop the citrus disease classification model, we preprocess the leaf dataset through stratified data splitting, oversampling, and augmentation techniques, then fine-tuning a pre-trained Residual Network 50 layers (ResNet50) model. MOGAE's effectiveness is demonstrated through comparative analyses with the Ensemble-based Genetic Algorithm Explainer (EGAE) and LIME, showing superior accuracy and interpretability using criteria such as numeric accuracy of explanation and Number of Function Evaluations (NFE). We assess accuracy both intuitively and numerically by measuring the Euclidean distance between expert-provided explanations and those generated by the explainer. The appendix also includes an extensive evaluation of MOGAE on the melanoma dataset, highlighting its versatility and robustness in other domains. The related implementation code for the fine-tuned ResNet50 and MOGAE is available at https://github.com/KhaosResearch/Plant-disease-explanation.

4. Phương pháp MOGAE

4.1. Phân đoạn



Hình: Ảnh được phân đoạn bởi SLIC thành n=41 siêu điểm ảnh.

- Phân đoạn bằng SLIC.
- Siêu điểm ảnh là tập hợp các điểm ảnh **có màu tương tự nhau** và ở **vị trí gần nhau**.
- Mục đích: chia nhỏ ảnh thành nhiều mảnh.

4. Phương pháp MOGAE

4.2. Thiết lập mô hình tối ưu

$$max \quad f(x) = \left[\frac{n-n_{as}+1}{n}, \hat{y}_c\right]$$

$$s.t. \quad x \in \{0;1\}^n$$

trong đó n là tổng số siêu điểm ảnh, n_{as} là số siêu điểm ảnh được bật trong x; $\hat{y}_c$ là xác suất dự đoán của ảnh tạo ra bởi x.

- Bài toán cực đại hóa 2 mục tiêu: **độ thưa** và **xác suất**.
- Biến tối ưu: vector **nhị phân** biểu diễn cho ảnh được làm nhiễu (0 và 1 lần lượt tương ứng với tắt và mở).

4. Phương pháp MOGAE

4.2. Thiết lập mô hình tối ưu đa mục tiêu



[0, 0, 0, 0, 0, 1, 0, 0, 0, 1, 0, 1, 0, 0,
1, 0, 0, 0, 0, 1, 1, 1, 0, 1, 0, 0, 0, 1,
0, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 0]

f = [0.7506, 0.0027]

4. Phương pháp MOGAE

4.2. Thiết lập mô hình tối ưu đa mục tiêu

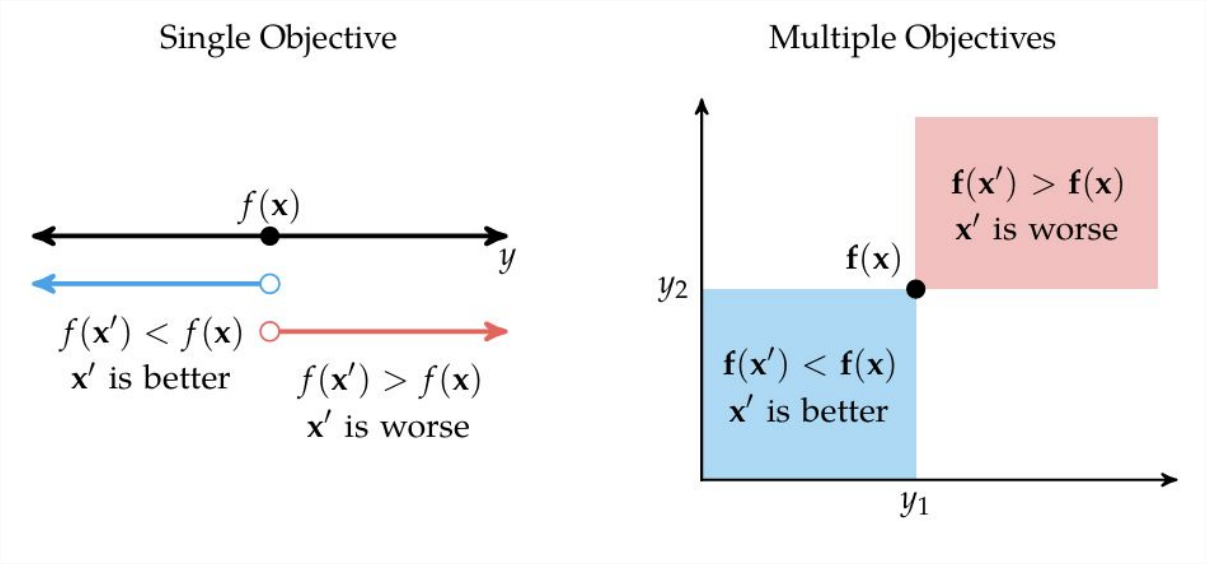
Quan hệ so sánh (bài toán max):

- Trong tối ưu đơn mục tiêu, có thể so sánh trực tiếp f(x) với f(x').
- Trong tối ưu đa mục tiêu, một nghiệm x được gọi là trội hơn (hay tốt hơn) x' khi và chỉ khi thỏa mãn điều kiện:

$$\begin{cases} \forall i \in I, \quad f_i(x) \geq f_i(x'); \\ \exists i \in I, \quad f_i(x) > f_i(x'). \end{cases}$$

4. Phương pháp MOGAE

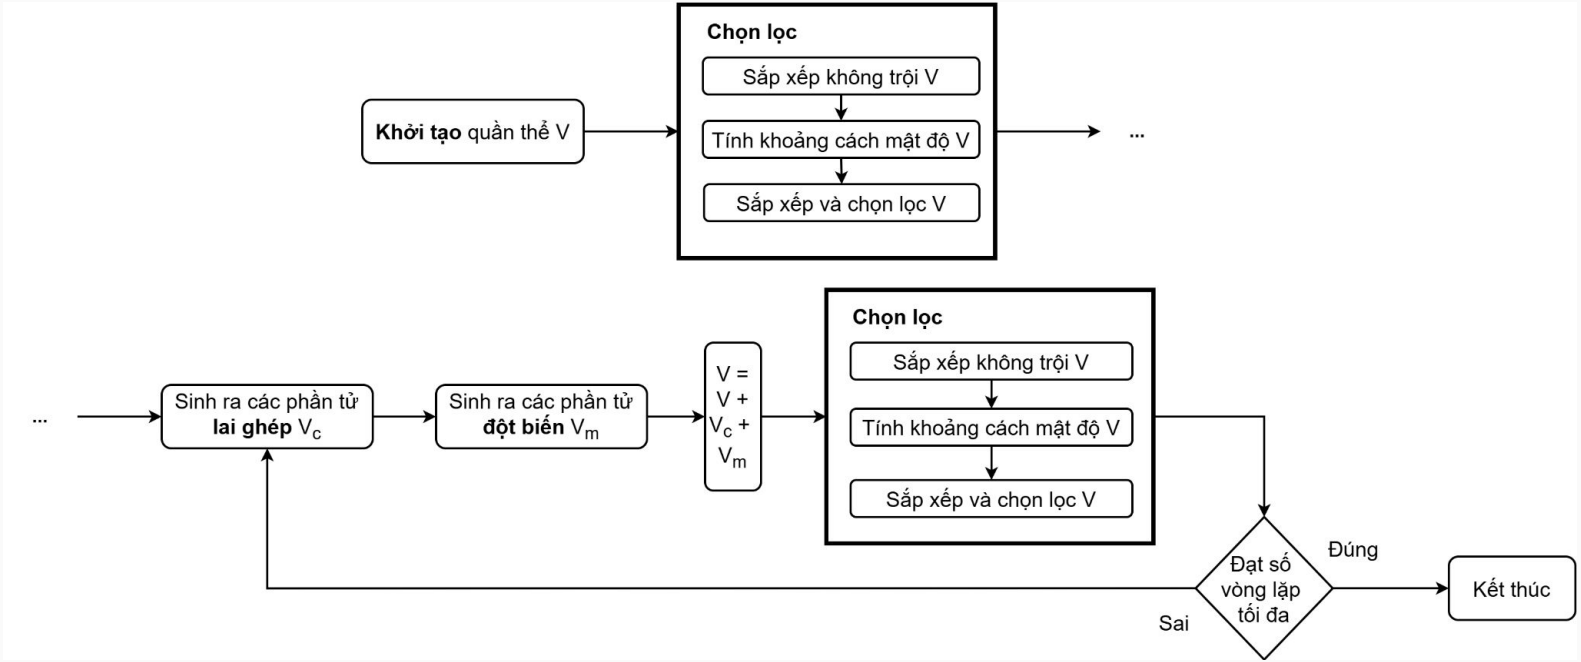
4.2. Thiết lập mô hình tối ưu đa mục tiêu



Hình: Quan hệ so sánh trong bài toán min.

4. Phương pháp MOGAE

4.3. Thuật toán NSGA-II



4. Phương pháp MOGAE

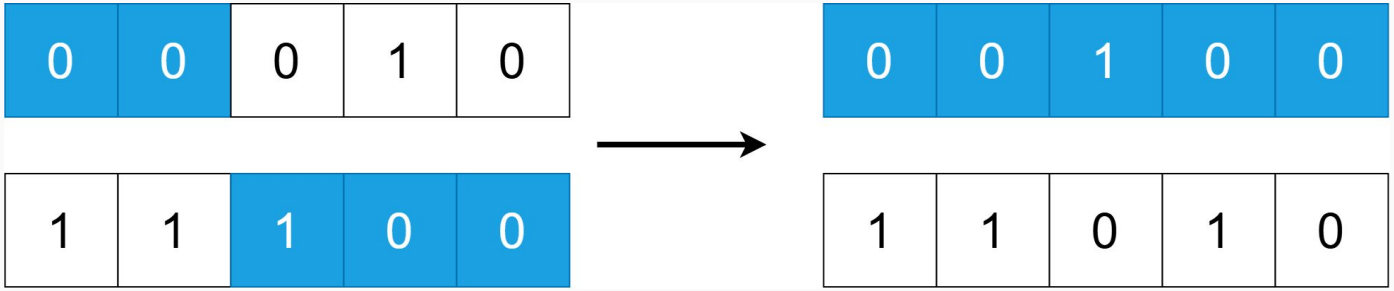
4.3. Thuật toán NSGA-II: Lai ghép

- Chọn cá thể lai ghép: **Lựa chọn giải đấu nhị phân**.
  - Chọn ngẫu nhiên 2 cá thể.
  - Giữ lại cá thể có hạng thấp hơn hơn.
  - Nếu hạng bằng nhau thì giữ cá thể có khoảng cách mật độ cao hơn.
- Lai ghép: **Lai ghép đơn điểm**.
  - Chọn ngẫu nhiên C từ 1 đến n-1.
  - $$z_i = \begin{cases} [x_1[1:C] \oplus x_2[C+1:H]], & \text{if } i = 1 \\ [x_2[1:C] \oplus x_1[C+1:H]], & \text{if } i = 2 \end{cases}$$

4. Phương pháp MOGAE

4.3. Thuật toán NSGA-II: Lai ghép

Ví dụ minh họa:



4. Phương pháp MOGAE

4.3. Thuật toán NSGA-II: Đột biến

Các phép đột biến

Đột biến lật bit:

$$BFM(X) = \begin{cases} 1 - x_i, & \text{nếu } i \in J, 1 \leq i \leq n \\ x_i, & \text{trong trường hợp còn lại} \end{cases}$$

Trong đó J là mảng chỉ số lấy ngẫu nhiên từ 1 đến n.

Đột biến bật bit:

$$Densify(X, \Omega) = \begin{cases} 1 - x_i, & \text{nếu } i \in \{i | x_i = 0\} \text{ và } r \leq \Omega \\ x_i \end{cases}$$

Trong đó Ω là giá trị xác suất thuộc [0, 1], r chọn ngẫu nhiên thuộc [0, 1].

Đột biến tắt bit:

$$Sparsify(X, \Omega) = \begin{cases} 1 - x_i, & \text{nếu } i \in \{i | x_i = 1\} \text{ và } r \leq \Omega \\ x_i \end{cases}$$

Trong đó Ω là giá trị xác suất thuộc [0, 1], r chọn ngẫu nhiên thuộc [0, 1].

4. Phương pháp MOGAE

4.3. Thuật toán NSGA-II: Đột biến

Ví dụ minh họa:

Đột biến lật bit:



Đột biến bật bit:



Đột biến tắt bit:



4. Phương pháp MOGAE

4.3. Thuật toán NSGA-II: Đột biến

Đột biến của MOGAE:

- Chủ yếu là **đột biến lật bit**.
- Khi xác suất cao nhất trong các cá thể hạng 1 không đổi sau 10 vòng lặp thì:
    1. TH1: Nếu xác suất cao nhất nhỏ hơn 33.33% thì trong vòng lặp này toàn bộ số cá thể đột biến được đột biến bằng **đột biến bật bit**.
    2. TH2: Nếu xác suất cao nhất lớn hơn 33.33% thì trong vòng lặp này toàn bộ số cá thể đột biến được đột biến bằng **đột biến tắt bit**.

4. Phương pháp MOGAE

4.4. Sơ đồ tổng quát



Hình: Sơ đồ phương pháp tổng quát

5. Đề xuất

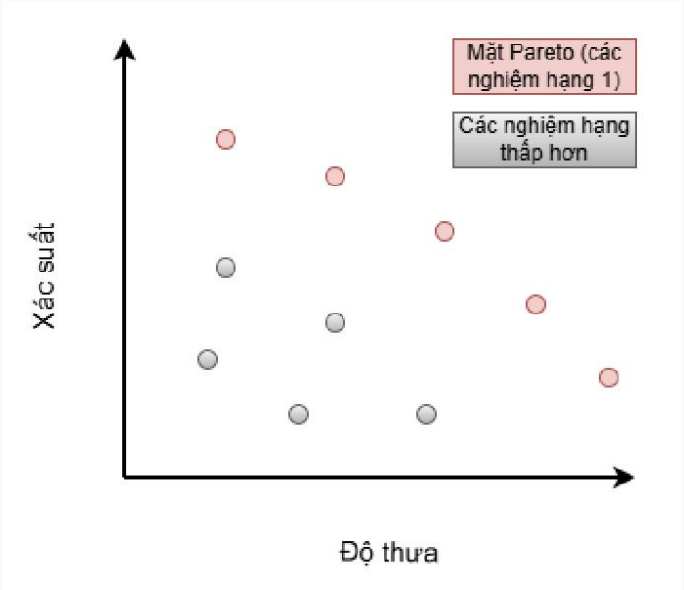
Nhận xét:

- Các nghiệm có số siêu điểm ảnh rất thấp hoặc rất cao dễ hội tụ hơn.
- Nghiệm tối ưu ở độ thưa thấp hơn thường chứa các siêu điểm ảnh có trong nghiệm tối ưu ở độ thưa cao hơn.

Cá thể có độ thưa cao → Đột biến bật bit

Cá thể có độ thưa thấp → Đột biến tắt bit

Tỉ lệ giữa đột biến bật và tắt bit điều chỉnh theo độ thưa trung bình của quần thể.



Hình: Minh họa mặt Pareto.

5. Đề xuất

i. Định lượng độ thưa: Mỗi cá thể i trong quần thể kích thước N được đánh giá độ thưa thông qua tỷ lệ siêu điểm ảnh bật (u_i) và tắt (v_i):

$$u_i = \frac{a_i}{N_{sp}}$$

$$v_i = \frac{N_{sp} - a_i}{N_{sp}} = 1 - u_i$$

trong đó, a_i là số siêu điểm ảnh được bật và N_{sp} là tổng số siêu điểm ảnh.

5. Đề xuất

ii. Phân bổ lượng cá thể đột biến: Tính toán số lượng cần đột biến bật bit (densify) và đột biến tắt bit (sparsify):

$$\bar{v} = \frac{1}{N} \sum_{i=1}^{N} v_i$$

$$N_{densify} = \lfloor N_m \cdot \bar{v} \rfloor$$

$$N_{sparsify} = N_m - N_{densify}$$

trong đó, N_m là tổng số cá thể đột biến được sinh ra.

5. Đề xuất

5.1. Sparsity-Biased Mutation (SBM)

iii. Tính xác suất thiên vị: Xác suất cá thể i được chọn tuân theo phân phối tỷ lệ thuận với hàm mũ k của độ thưa/dày

$$p_i^{densify} = \frac{v_i^k}{\sum_{j=1}^{N} v_j^k}$$

$$p_i^{sparsify} = \frac{u_i^k}{\sum_{j=1}^{N} u_j^k}$$

trong đó, hệ số $k >= 1$ khuếch đại độ thiên vị.

5. Đề xuất

5.1. Sparsity-Biased Mutation (SBM)

iv. Cập nhật xác suất đột biến: Xác suất áp dụng đột biến ở lần gọi tiếp theo tăng dần dựa trên hằng số δ và bị kiểm soát bởi giới hạn trần Ω_{max} .

$$\Omega_{densify}^{t+1} = \min(\max(\Omega_{densify}^{t} + \delta \cdot (1 - \Omega_{densify}^{t}), 0), \Omega_{max})$$

$$\Omega_{sparsify}^{t+1} = \min(\max(\Omega_{sparsify}^{t} + \delta \cdot (1 - \Omega_{sparsify}^{t}), 0), \Omega_{max})$$

5. Đề xuất

5.2. Decaying Sparsity-Biased Mutation (DSBM)

iii. Tính xác suất thiên vị: Xác suất cá thể i được chọn tuân theo phân phối tỷ lệ thuận với hàm mũ k của độ thưa/dày

$$p_i^{densify} = \frac{v_i^{k^{(t)}}}{\sum_{j=1}^{N} v_j^{k^{(t)}}}$$

$$p_i^{sparsify} = \frac{u_i^{k^{(t)}}}{\sum_{j=1}^{N} u_j^{k^{(t)}}}$$

trong đó, hệ số k >= 1 khuếch đại độ thiên vị, thay đổi sau mỗi lần DSBM được gọi (0 <= γ <= 1) :

$$k^{(t+1)} = \gamma \cdot k^{(t)}$$

5. Đề xuất

5.2. Decaying Sparsity-Biased Mutation (DSBM)

iv. Xác suất đột biến: Xác suất Ω cố định:

$$\Omega_{densify} = \Omega_{sparsify} = \Omega_{const}$$

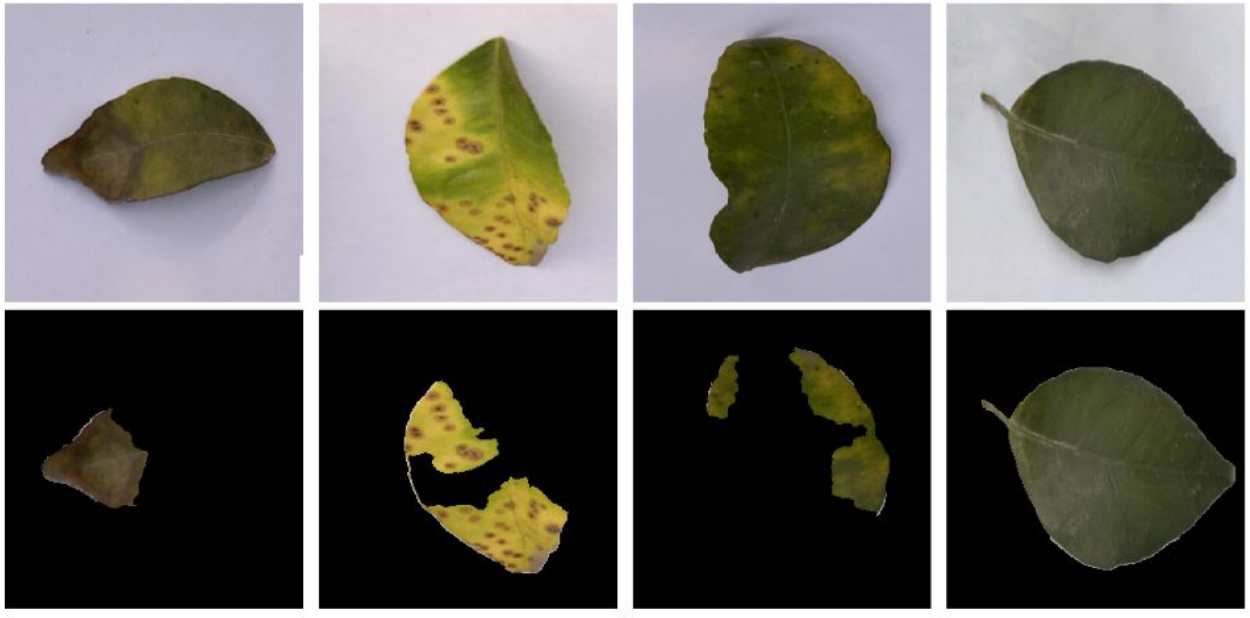
6. Thực nghiệm

Bảng: Tập dữ liệu Bệnh lá cây họ cam quýt (Citrus Leaf Diseases).

Thông tin	Mô tả
Số mẫu	596
Kích thước và số kênh	$256 \times 256 \times 3$
Không gian màu	RGB
Các lớp	Black spot (171), Canker (163), Greening (204), Healthy (58)
Train / Val / Test	80% / 10% / 10%

6. Thực nghiệm

Các mẫu dữ liệu được thực nghiệm



6. Thực nghiệm: Độ đo đánh giá

Độ lỗi chuẩn hóa (Normalized error):

$$normalized_error = \frac{error}{max_error}$$

với

$$error = \sqrt{\sum_{i=1}^{n}(AE_i - CE_i)^2}$$

trong đó AE là nhãn, CE là ảnh giải thích và n là tổng số điểm ảnh.

6. Thực nghiệm: Độ đo đánh giá

IoU Score:

$$IoU = \frac{|A \cap B|}{|A \cup B|}$$

Trong đó, A là tập hợp các điểm ảnh được bật trong ảnh giải thích, B là tập hợp các điểm ảnh được bật trong ảnh nhãn.

6. Thực nghiệm: Độ đo đánh giá

Insertion/Deletion Score:

$$\begin{cases} Insertion_Score & = f_c(O) - f_c(I) \\ Deletion_Score & = f_c(O) - f_c(D) \end{cases}$$

Trong đó, f_c là xác suất dự đoán của mô hình cho lớp cần giải thích, O là ảnh gốc, I và D lần lượt là ảnh chèn và xóa được tạo ra bởi:

$$D^{(i,j)} = \begin{cases} b^{(i,j)} & \text{nếu } M^{(i,j)} = 1 \\ O^{(i,j)} & \text{nếu } M^{(i,j)} = 0 \end{cases} \qquad I^{(i,j)} = \begin{cases} O^{(i,j)} & \text{nếu } M^{(i,j)} = 1 \\ b^{(i,j)} & \text{nếu } M^{(i,j)} = 0 \end{cases}$$

Trong đó M là ma trận mặt nạ giải thích nhị phân (cùng kích thước với O).

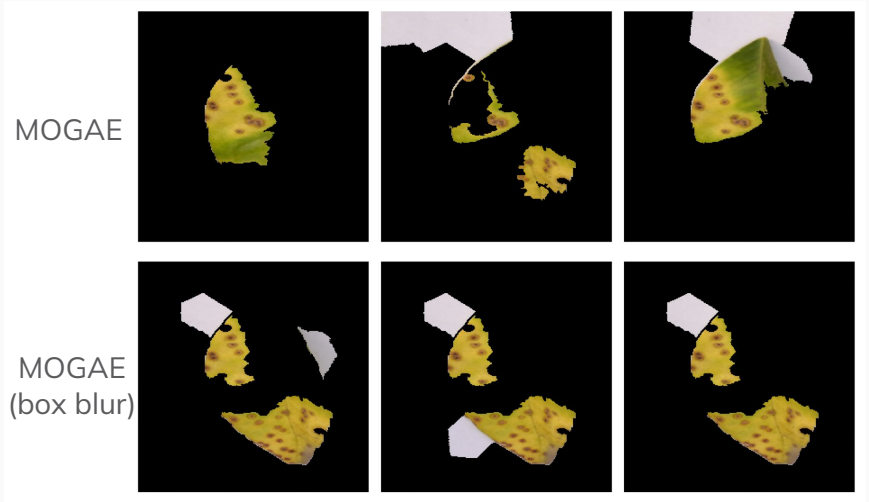
6. Thực nghiệm: Độ đo đánh giá

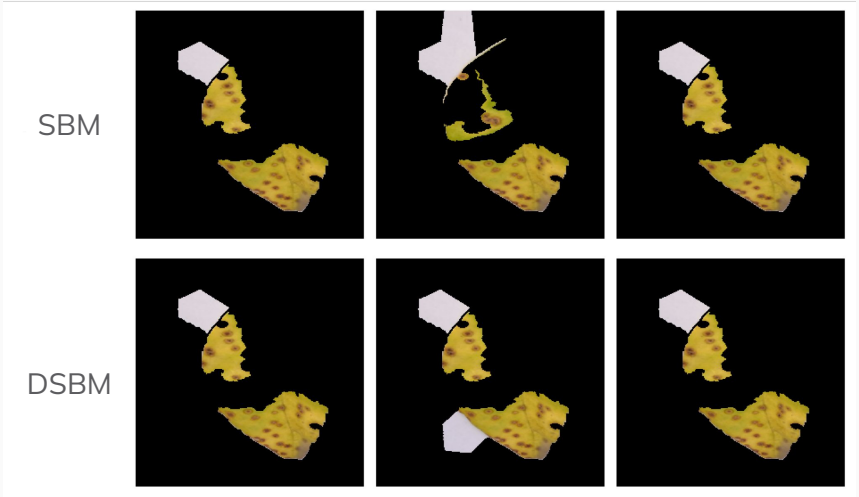
So sánh hiệu quả của 4 thuật toán

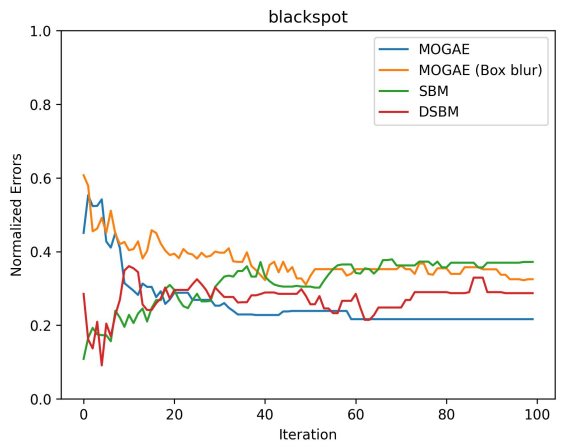
1. MOGAE [1]
2. MOGAE + Box blur (11 x 11)
3. SBM
4. DSBM

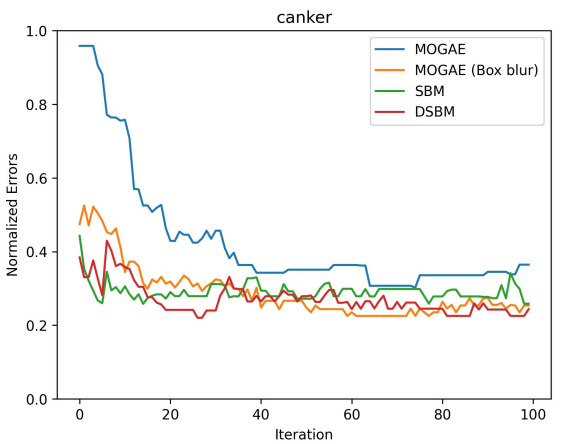
6. Thực nghiệm: Độ đo đánh giá

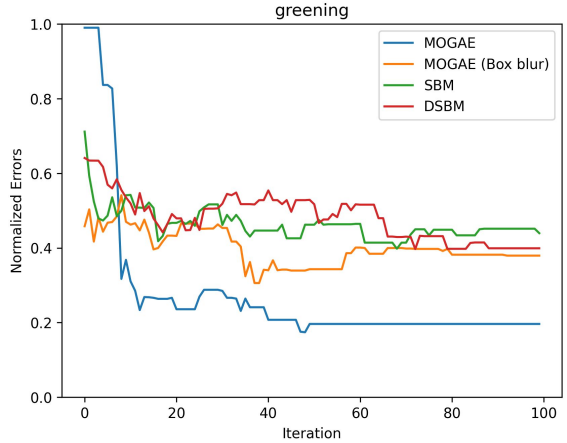
Minh hoạ kết quả của các thuật toán

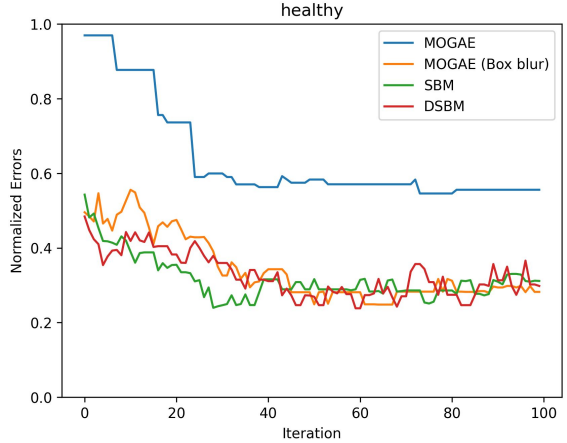


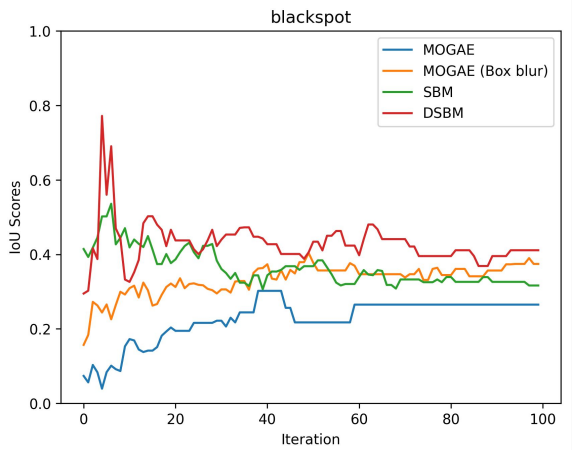


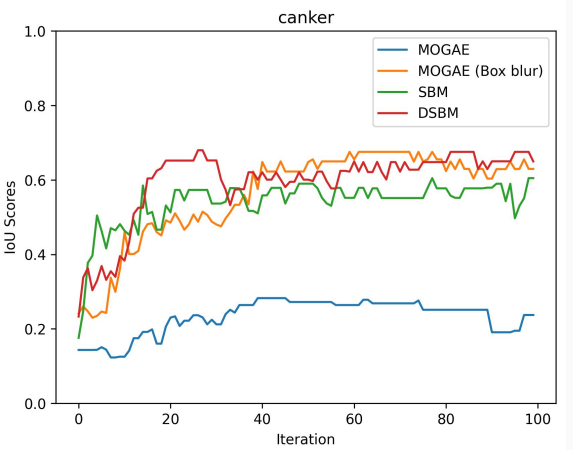

blackspot
MOGAE
MOGAE (Box blur)
SBM
DSBM
Normalized Errors
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100

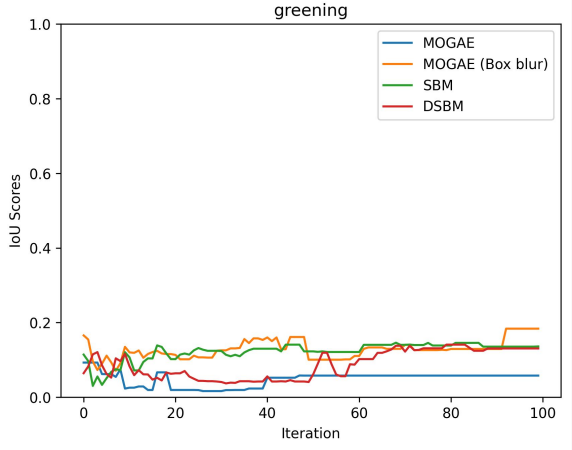

canker
MOGAE
MOGAE (Box blur)
SBM
DSBM
Normalized Errors
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100

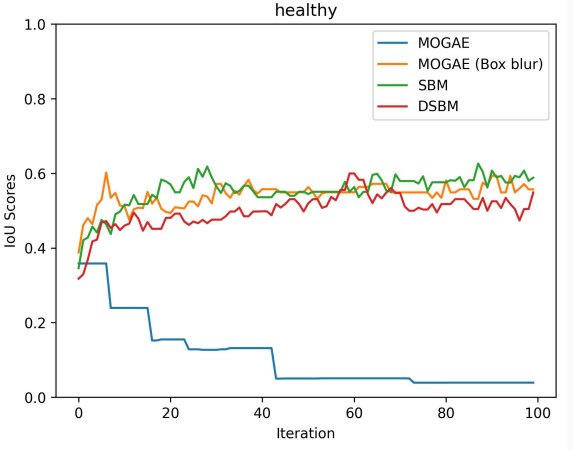

greening
MOGAE
MOGAE (Box blur)
SBM
DSBM
Normalized Errors
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100


healthy
MOGAE
MOGAE (Box blur)
SBM
DSBM
Normalized Errors
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100


blackspot
MOGAE
MOGAE (Box blur)
SBM
DSBM
IoU Scores
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100


canker
MOGAE
MOGAE (Box blur)
SBM
DSBM
IoU Scores
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100


greening
MOGAE
MOGAE (Box blur)
SBM
DSBM
IoU Scores
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100


healthy
MOGAE
MOGAE (Box blur)
SBM
DSBM
IoU Scores
Iteration
0.0
0.2
0.4
0.6
0.8
1.0
0
20
40
60
80
100

6. Thực nghiệm: Độ đo đánh giá

Insertion/Deletion Score

Bảng 4.1: Insertion core sau 100 vòng lặp.

Nhãn	MOGAE	MOGAE (Box blur)	SBM	DSBM
Black spot	$\mathbf{2.511 \times 10^{-5}}$	0.05894	0.06387	0.04321
Canker	8.980×10^{-6}	$\mathbf{7.153 \times 10^{-7}}$	9.537×10^{-7}	8.345×10^{-7}
Greening	0.0007725	0.0003567	**0.0002993**	0.0003748
Healthy	0.01987	3.584×10^{-5}	$\mathbf{1.538 \times 10^{-5}}$	3.139×10^{-5}

Bảng 4.2: Deletion score sau 100 vòng lặp.

Nhãn	MOGAE	MOGAE (Box blur)	SBM	DSBM
Black spot	3.451×10^{-5}	0.05738	**0.06552**	0.04312
Canker	0	$\mathbf{6.358 \times 10^{-7}}$	5.563×10^{-7}	$\mathbf{6.358 \times 10^{-7}}$
Greening	2.571×10^{-5}	0.002633	**0.005340**	0.003639
Healthy	1.152×10^{-6}	0.001155	**0.001460**	0.001177

7. Một số phân tích bổ sung

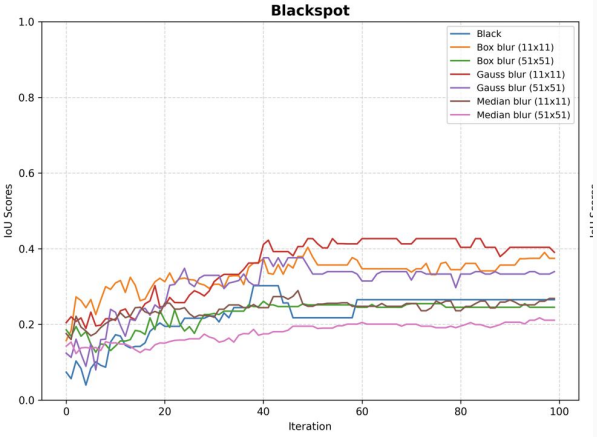
So sánh hiệu quả của các bộ lọc làm mờ:

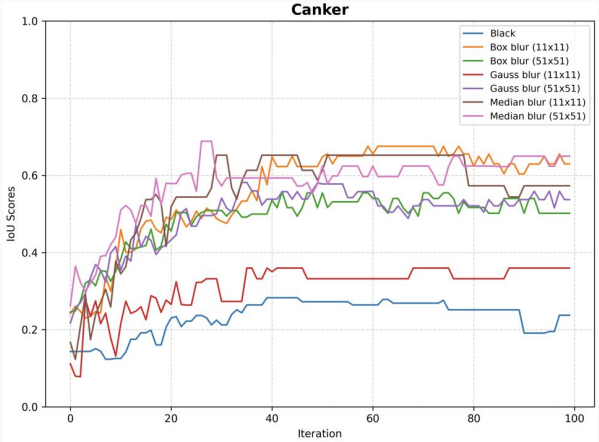
- Bộ lọc trung bình
- Bộ lọc Gauss
- Bộ lọc trung vị

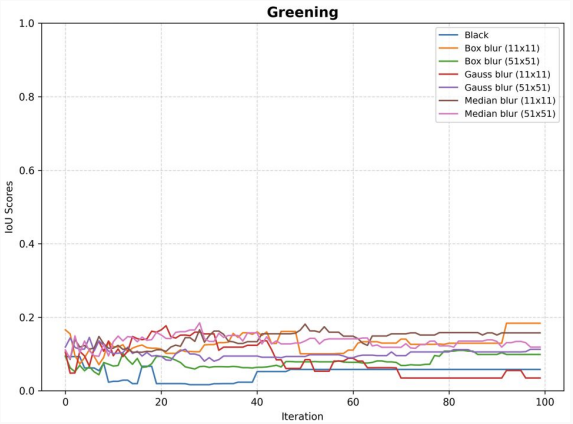
Kích thước: 11 x 11 và 51 x 51.

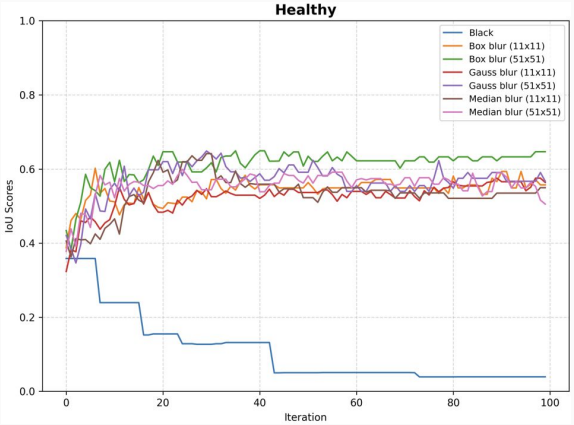
7. Một số phân tích bổ sung

Điểm IoU của các bộ lọc làm mờ trên các mẫu dữ liệu









8. Kết luận và hướng nghiên cứu tương lai

Đóng góp

Đề xuất phép đột biến cải tiến có thể làm tăng độ chính xác của lời giải thích.

Khảo sát hiệu quả của một số bộ lọc làm mờ.

Hướng đi tương lai

Khám phá tiềm năng của các thuật toán tiến hóa khác.

Thực hiện trên nhiều tập dữ liệu hơn để kiếm chứng mức độ tổng quát của thuật toán.

Thử nghiệm thêm một số thuật toán phân đoạn khác ngoài SLIC.

Cảm ơn thầy cô và các bạn
đã lắng nghe

Tài liệu tham khảo

[1] Nematzadeh, H., García-Nieto, J., Hurtado, S., Aldana-Montes, J. F., and Navas-Delgado, I., “Model-agnostic local explanation: Multi-objective genetic algorithm explainer,” Engineering Applications of Artificial Intelligence, vol. 139, 2025, issn: 09521976. doi: 10.1016/j.engappai. 2024.109628.

[2] Molnar, C., Interpretable machine learning : a guide for making black box models explainable. Christoph Molnar, 2025, p. 379, isbn: 9783911578035.

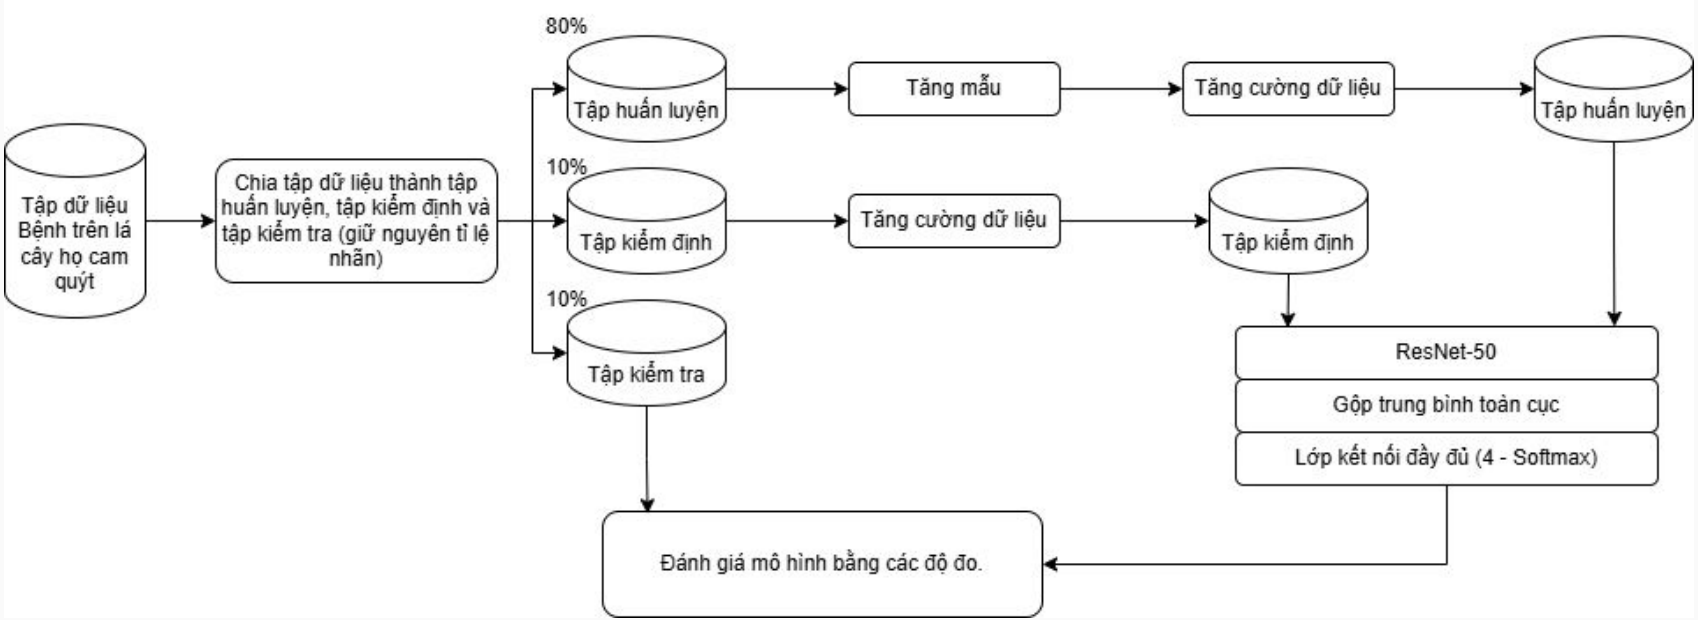
Phụ lục

Kiến trúc mô hình ResNet-50

Tên lớp / Khối	Kích thước đầu ra	Cấu trúc chi tiết (kích thước - số lượng)	Số lượng khối
Conv1 Max Pooling	112 x 112 56 x 56	7 x 7, 64 bộ lọc, stride 2 3 x 3, stride 2	1
Conv2_x	56 x 56	[1x1, 3x3, 1x1] [64, 64, 256]	x3 (9 lớp)
Conv3_x	28 x 28	[1x1, 3x3, 1x1] [128, 128, 256]	x4 (12 lớp)
Conv4_x	14 x 14	[1x1, 3x3, 1x1] [256, 256, 1024]	x6 (18 lớp)
Conv5_x	7 x 7	[1x1, 3x3, 1x1] [512, 512, 2048]	x3 (9 lớp)
Classifier	1000 (mô hình gốc) **4 (đề tài)**	Global Average Pooling Fully Connected + Softmax	1 lớp

Phụ lục

Tinh chỉnh mô hình ResNet-50



Phụ lục

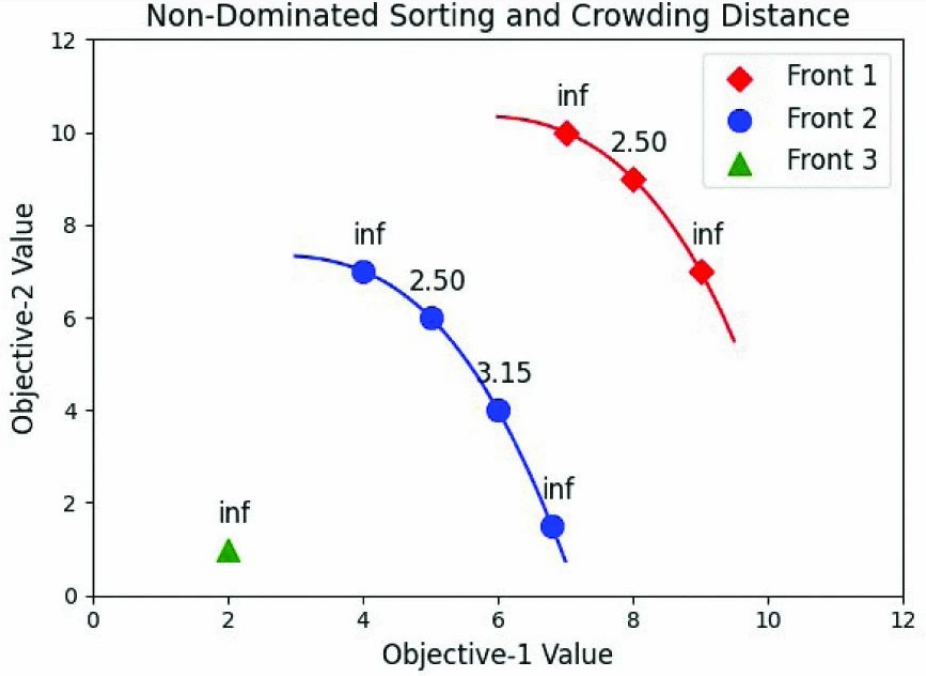
Tinh chỉnh mô hình ResNet-50

Các phép tăng cường dữ liệu:

- Phép xoay
- Phép dịch theo chiều dọc
- Phép dịch theo chiều ngang
- Phép lật theo chiều ngang

Phụ lục

Sắp xếp không trội và khoảng cách mật độ



Phụ lục

Thuật toán sắp xếp không trội

Algorithm 3 Non-dominated sorting

Input: Pop
Output: Pop, Fronts

```
for each candidate solution P in Pop do
    P.DominationSet ← EmptySet;   P.DominatedCount ← 0
end for
Fronts{1} ← []
for i=1 to nPop do
    for j=i+1 to nPop do
        P1 ← Pop[i];   P2 ← Pop[j]
        if P1 Dominate P2 then   ▷ Apply changes if P1 dominates P2 or vice versa
            P1.DominationSet.append(j)
            P2.DominatedCount ← P2.DominatedCount+1
        end if
        Pop[i] ← P1;  Pop[j] ← P2
    end for
    if Pop[i].DominatedCount==0 then
        Fronts{1}.append(i); Pop[i].rank=1
    end if
end for
k ← 1
while True do
    Q ← []
    for i=Fronts{k} do
        P1 ← Pop[i]
        for j=P1.DominationSet do
            P2 ← Pop[j];   P2.DominatedCount ← P2.DominatedCount-1
            if P2.DominatedCount==0 then
                Q.append(j);   P2.rank ← k+1
            end if
            Pop[j] ← P2
        end for
    end for
    if isempty(Q) then
        break
    end if
    Fronts{k + 1} ← Q;   k ← k + 1
end while
Return Pop, Fronts
```

Phụ lục

Sắp xếp không trội và khoảng cách mật độ

Công thức tính khoảng cách mật độ:

$$d_i^j = \frac{|Obj_j^{i+1} - Obj_j^{i-1}|}{Obj_j^{max} - Obj_j^{min}}$$

$$d_i = d_i^1 + d_i^2$$

Phụ lục

Thuật toán tính khoảng cách mật độ

Algorithm 4 Crowding distance

Input: Pop, Fronts
Output: Pop

front_layers ← numel(Fronts)
for layers in front_layers **do**
    h ← |Fronts{layers}|
    for i=1 to h **do**
        $CD_i \leftarrow 0$
    end for
    nObj=len(Fronts{layers}.Fit)
    for j=1 to nObj **do**
        sort (Fronts{layers},f_j)
        $CD_1 \leftarrow$ inf; $CD_h \leftarrow$ inf
        for i=2 to h-1 **do**
            $CD_i \leftarrow CD_i + d_i^j$ based on Eqs. (16) and (17)
        end for
    end for
    Update the CD values of corresponding solutions in Pop with related CDs
end for
Return Pop

Phụ lục

Bảng các siêu tham số của NSGA-II

Tên tham số	Giá trị
Kích thước quần thể (nPop)	35
Xác suất lai ghép (P_c)	0.9
Xác suất đột biến (P_{m})	0.4
Kích thước quần thể lai ghép ($\mathrm{nPop_c}$)	$\mathrm{nPop_c} = 2 \times \left[P_{\mathrm{c}} \times \left(\frac{\mathrm{nPop}}{2}\right)\right] = 32$
Kích thước quần thể đột biến ($\mathrm{nPop_m}$)	$\mathrm{nPop_m} = [P_{\mathrm{m}} \times \mathrm{nPop}] = 14$
Phép lai ghép	Lai ghép đơn điểm
Phép đột biến	Các thuật toán 4, 6 và 7
Số k trong 6 và 7	2.0
Số γ trong 7	0.7
Chọn lọc	Sắp xếp không trội và khoảng cách mật độ
Số vòng lặp tối đa	100
Tiêu chuẩn dừng	Đạt số vòng lặp tối đa

Phụ lục

Các bộ lọc làm mờ

Làm mờ ảnh bằng bộ lọc trung bình và Gauss được thực hiện thông qua phép tích chập:

$$g(x,y) = (f * K)(x,y) = \sum_{i=-k}^{k} \sum_{j=-k}^{k} K(i,j) f(x-i, y-j)$$

Trong đó, $f(x,y)$ là ảnh đầu vào, $g(x,y)$ là ảnh đầu ra,
K là hạt nhân kích thước $(2k+1) \times (2k+1)$.

Phụ lục

Các bộ lọc làm mờ

Dạng tổng quát của **bộ lọc trung bình**

$$K = \frac{1}{(2k+1)^2} \begin{bmatrix} 1 & 1 & \cdots & 1 \\ 1 & 1 & \cdots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \cdots & 1 \end{bmatrix}_{(2k+1)\times(2k+1)}$$

Phụ lục

Các bộ lọc làm mờ

Dạng tổng quát của **bộ lọc Gauss**

$$K(i,j) = \frac{1}{\sum_{u=-k}^{k}\sum_{v=-k}^{k}\exp\left(-\frac{u^2+v^2}{2\sigma^2}\right)}\exp\left(-\frac{i^2+j^2}{2\sigma^2}\right)$$

Phụ lục

Các bộ lọc làm mờ

Làm mờ bằng **bộ lọc trung vị** không sử dụng phép tích chập như bộ lọc trung bình và Gauss mà sử dụng phép sắp xếp để tìm trung vị trong một vùng lân cận:

$$g(x,y) = \underset{(i,j)\in K}{\text{median}}\{f(x+i, y+j)\}$$

Trong đó K là cửa sổ trượt có tâm tại tọa độ (x, y).

Phụ lục

Thuật toán SBM

Algorithm 6 Đột biến cải tiến 1

function ImprovedMutation1(Pop, k)
  $Pop_m \leftarrow$ Khởi tạo quần thể đột biến rỗng $\emptyset$
  $N \leftarrow |Pop|$ ▷ Kích thước quần thể
  $N_{sp} \leftarrow$ tổng số siêu điểm ảnh
  $N_m \leftarrow$ số lượng cá thể đột biến được sinh ra
  Khởi tạo vector: $\mathbf{u}, \mathbf{v} \in \mathbb{R}^N$
  for $i \leftarrow 1$ to N **do**
    $a_i \leftarrow Pop_i.n_{as}$
    $u_i \leftarrow a_i / N_{sp}$ ▷ Chuẩn hóa số siêu điểm ảnh bật
    $v_i \leftarrow (N_{sp} - a_i)/N_{sp}$ ▷ Chuẩn hóa số siêu điểm ảnh tắt
  $\bar{v} \leftarrow \frac{1}{N}\sum_{i=1}^{N} v_i$ ▷ Tỉ lệ số siêu điểm ảnh bị tắt trung bình của quần thể hiện tại
  $N_{densify} \leftarrow \lfloor N_m \cdot \bar{v} \rfloor$
  $N_{sparsify} \leftarrow N_m - N_{densify}$
  ▷ **Tính xác suất mỗi cá thể được chọn để làm dày**
  $\mathbf{w}^{densify} \leftarrow \mathbf{v}^k$
  if $\sum_{i=1}^{N} w_i^{densify} > 0$ **then**
    $\mathbf{p}^{densify} \leftarrow \mathbf{w}^{densify} / \sum_{i=1}^{N} w_i^{dens}$
  else
    $\mathbf{p}^{densify} \leftarrow \left(\frac{1}{N}, \ldots, \frac{1}{N}\right)$
  ▷ **Tính xác suất mỗi cá thể được chọn để làm dày**
  $\mathbf{w}^{sparsify} \leftarrow \mathbf{u}^k$
  if $\sum_{i=1}^{N} w_i^{sparsify} > 0$ **then**
    $\mathbf{p}^{sparsify} \leftarrow \mathbf{w}^{sparsify} / \sum_{i=1}^{N} w_i^{sparsify}$
  else
    $\mathbf{p}^{sparsify} \leftarrow \left(\frac{1}{N}, \ldots, \frac{1}{N}\right)$
  if $N_{densify} > 0$ **then**
    for $i \leftarrow 1$ to $N_{densify}$ **do**
      $x \leftarrow$ Lấy mẫu không hoàn lại từ phân phối $\mathbf{p}^{densify}$
      $Pop_m \leftarrow Pop_m \cup \{\text{Densify}(x, \Omega_{densify})\}$
  if $N_{sparsify} > 0$ **then**
    for $i \leftarrow 1$ to $N_{sparsify}$ **do**
      $x \leftarrow$ Lấy mẫu không hoàn lại từ phân phối $\mathbf{p}^{sparsify}$
      $Pop_m \leftarrow Pop_m \cup \{\text{Sparsify}(x, \Omega_{sparsify})\}$
  ▷ **Cập nhật xác suất đột biến**
  $\Omega_{densify} \leftarrow \min\left(\max\left(\Omega_{densify} + \delta \cdot (1 - \Omega_{densify}), 0\right), \Omega\right)$
  $\Omega_{sparsify} \leftarrow \min\left(\max\left(\Omega_{sparsify} + \delta \cdot (1 - \Omega_{sparsify}), 0\right), \Omega\right)$
  return Pop_m

28

Phụ lục

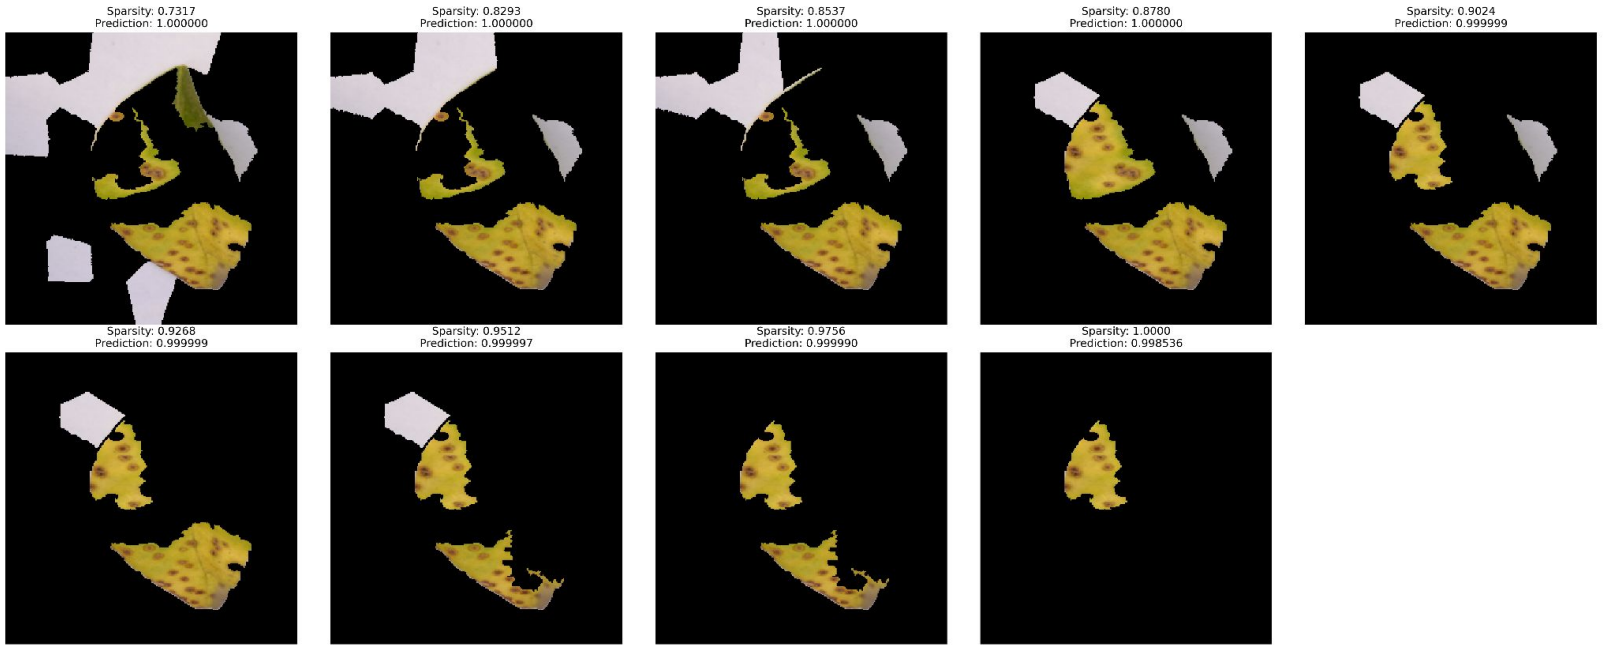
Thuật toán DSBM

Algorithm 7 Đột biến cải tiến 2

function ImprovedMutation2(Pop)
  $Pop_m \leftarrow$ Khởi tạo quần thể đột biến rỗng $\emptyset$
  $N \leftarrow |Pop|$ ▷ Kích thước quần thể
  $N_{sp} \leftarrow$ tổng số siêu điểm ảnh
  $N_m \leftarrow$ số lượng cá thể đột biến được sinh ra
  Khởi tạo vector: $\mathbf{u}, \mathbf{v} \in \mathbb{R}^N$
  for $i \leftarrow 1$ to N **do**
    $a_i \leftarrow Pop_i.n_{as}$
    $u_i \leftarrow a_i / N_{sp}$ ▷ Chuẩn hóa số siêu điểm ảnh bật
    $v_i \leftarrow (N_{sp} - a_i)/N_{sp}$ ▷ Chuẩn hóa số siêu điểm ảnh tắt
  $\bar{v} \leftarrow \frac{1}{N}\sum_{i=1}^{N} v_i$ ▷ Tỉ lệ số siêu điểm ảnh bị tắt trung bình của quần thể hiện tại
  $N_{densify} \leftarrow \lfloor N_m \cdot \bar{v} \rfloor$
  $N_{sparsify} \leftarrow N_m - N_{densify}$
  ▷ **Tính xác suất mỗi cá thể được chọn để làm dày**
  $\mathbf{w}^{densify} \leftarrow \mathbf{v}^k$
  if $\sum_{i=1}^{N} w_i^{densify} > 0$ **then**
    $\mathbf{p}^{densify} \leftarrow \mathbf{w}^{densify} / \sum_{i=1}^{N} w_i^{dens}$
  else
    $\mathbf{p}^{densify} \leftarrow \left(\frac{1}{N}, \ldots, \frac{1}{N}\right)$
  ▷ **Tính xác suất mỗi cá thể được chọn để làm dày**
  $\mathbf{w}^{sparsify} \leftarrow \mathbf{u}^k$
  if $\sum_{i=1}^{N} w_i^{sparsify} > 0$ **then**
    $\mathbf{p}^{sparsify} \leftarrow \mathbf{w}^{sparsify} / \sum_{i=1}^{N} w_i^{sparsify}$
  else
    $\mathbf{p}^{sparsify} \leftarrow \left(\frac{1}{N}, \ldots, \frac{1}{N}\right)$
  if $N_{densify} > 0$ **then**
    for $i \leftarrow 1$ to $N_{densify}$ **do**
      $x \leftarrow$ Lấy mẫu không hoàn lại từ phân phối $\mathbf{p}^{densify}$
      $Pop_m \leftarrow Pop_m \cup \{\text{Densify}(x, \Omega_{densify})\}$ ▷ $\Omega_{densify}$ cố định, rất nhỏ
  if $N_{sparsify} > 0$ **then**
    for $i \leftarrow 1$ to $N_{sparsify}$ **do**
      $x \leftarrow$ Lấy mẫu không hoàn lại từ phân phối $\mathbf{p}^{sparsify}$
      $Pop_m \leftarrow Pop_m \cup \{\text{Sparsify}(x, \Omega_{sparsify})\}$ ▷ $\Omega_{sparsify}$ cố định, rất nhỏ
  ▷ **Cập nhật số mũ** k
  $k \leftarrow \gamma k$ ▷ $\gamma \in (0, 1)$
  return Pop_m

Phụ lục

Minh họa các nghiệm trong mặt Pareto (thuật toán kết hợp với bộ lọc trung bình)



Phụ lục

Điểm IoU sau 100 vòng lặp của các bộ lọc làm mờ

Bộ lọc	Blackspot	Canker	Greening	Healthy
Black	0.26511	0.23723	0.05794	0.03907
Box blur (11×11)	0.37441	0.62966	**0.18372**	0.55712
Box blur (51×51)	0.24509	0.50148	0.09872	**0.64666**
Gauss blur (11×11)	**0.39027**	0.35947	0.03464	0.56387
Gauss blur (51×51)	0.33930	0.53700	0.11266	0.56690
Median blur (11×11)	0.26841	0.57288	0.15744	0.54954
Median blur (51×51)	0.21093	**0.64966**	0.11868	0.50527